

Text-to-SQL 项目评估指标问题与解决方案

COMP9444 AI4DS Project

2026 年 7 月 28 日

摘要

本文分析当前 SQL 生成项目中测试结果较低的问题，并提出适用于现有数据条件的评估方案。重点讨论严格字符串完全匹配（Exact Match）与 SQL 语义等价之间的区别，以及在缺少真实数据库实例时如何选择合理的评价指标。本文建议保留 Exact Match 作为严格基准，同时加入 Normalized Exact Match 和 SQL Validity Rate，并明确说明当前数据条件下无法可靠计算 Execution Accuracy。

1 问题背景

当前项目使用的数据集为 AI4DS/sql_generator_no_cot。数据文件包含两个主要字段：

- **prompt**: 包含数据库 schema 描述和自然语言问题；
- **response**: 对应的目标 SQL 查询。

数据集页面中的任务说明是根据 schema 和问题生成有效的 SQLite 查询，而不是直接提供一个可以执行所有查询的数据库文件¹。

因此，需要区分以下两个概念：

- **训练数据集**: 保存 “prompt-SQL” 配对，用于训练模型；
- **数据库实例**: 包含诸如 users、orders 或 patients 等真实表及其数据，用于执行 SQL。

当前 CSV 不是数据库实例。即使将 CSV 导入 SQLite，它也只能形成一个包含 prompt 和 response 两列的表，不能执行目标 SQL 中引用的原始业务表。

¹数据集页面: https://huggingface.co/datasets/AI4DS/sql_generator_no_cot/viewer

2 当前数据处理结果

当前 pipeline 的主要流程为：

1. 读取原始 CSV；
2. 删除完全重复的行；
3. 去掉 prompt 的首尾空格；
4. 删除 response 中的 Markdown SQL 代码块标记；
5. 按固定随机种子划分训练集、验证集和测试集；
6. 使用 T5 tokenizer 生成 input_ids、attention_mask 和 labels；
7. 使用 DataCollatorForSeq2Seq 和 PyTorch DataLoader 生成 batch。

根据当前运行结果，原始数据有 9399 条记录，检测到 2 条重复记录，清洗后剩余 9397 条：

表 1: 当前数据划分结果		
Split	样本数	约占比例
Train	7517	80%
Validation	940	10%
Test	940	10%

该划分逻辑本身是合理的。测试集的参考答案是清洗后的 sql 字段，而不是模型生成的结果。

3 为什么 Exact Match 可能很低

如果 evaluation 使用如下判断：

```
prediction == reference
```

那么它计算的是严格的字符串完全匹配。以下两个 SQL 可能表达相同的意图，但严格匹配会将其判定为不同：

```
SELECT name FROM users WHERE age > 18
select name from users where 18 < age;
```

此外，以下差异也可能导致 Exact Match 失败：

- 大小写不同;
- 换行或多余空格不同;
- SQL 结尾是否有分号不同;
- 等价的条件顺序不同;
- 使用不同但等价的 JOIN 或子查询写法。

因此, 10% 的 Exact Match 只能说明约 10% 的预测字符串与参考字符串完全相同, 不能直接说明模型只有 10% 的 SQL 语义能力。

需要强调的是, Exact Match 并不是错误指标。它是一个严格、可复现的指标, 适合用来比较不同模型。但它不应该被单独称为完整的“SQL 语义准确率”。

4 推荐的评估指标

4.1 Exact Match

Exact Match 保留作为严格基准:

$$\text{Exact Match} = \frac{\sum_{i=1}^N \mathbb{I}(\hat{y}_i = y_i)}{N}$$

其中 $\hat{y}_i$ 是模型生成的 SQL, y_i 是参考 SQL。

4.2 Normalized Exact Match

在比较之前进行基础标准化, 可以消除大小写、空格和结尾分号带来的表面差异:

```
def normalize_sql(sql):
    sql = sql.strip().lower()
    sql = sql.rstrip(";")
    sql = " ".join(sql.split())
    return sql

def normalized_exact_match(predictions, references):
    correct = 0
    for prediction, reference in zip(predictions, references):
        if normalize_sql(prediction) == normalize_sql(reference):
            correct += 1
    return correct / len(references)
```

该指标比原始 Exact Match 更宽松，但仍然不能证明两个 SQL 在所有数据库上的语义完全等价。

4.3 SQL Validity Rate

SQL Validity Rate 衡量生成的字符串是否能够被 SQL parser 解析。可以使用 sqlglot:

```
import sqlglot

def is_valid_sql(sql):
    try:
        sqlglot.parse_one(sql, read="sqlite")
        return True
    except Exception:
        return False

def sql_validity_rate(predictions):
    valid_count = sum(is_valid_sql(sql) for sql in predictions)
    return valid_count / len(predictions)
```

SQL parser 可以检查基本语法，但不能保证表名、列名或查询逻辑一定正确。因此 Validity Rate 不能替代 Exact Match，而应该作为辅助指标。

5 没有数据库实例时的限制

真正的 Execution Accuracy 需要以下条件：

1. 找到每一条样本对应的数据库实例；
2. 数据库 schema 与 prompt 中的 schema 匹配；
3. 数据库表中包含真实数据；
4. 预测 SQL 和参考 SQL 在相同数据库上执行；
5. 比较两条 SQL 的执行结果。

当前提供的 CSV 没有这些数据库实例，因此不应随便创建一个 SQLite 数据库，也不应下载一个名称相似但不匹配的数据库。否则得到的 Execution Accuracy 没有可靠意义。

如果后续能够找到正确的原始数据库，可以把执行评估作为独立模块加入，而不需要改变 baseline 的训练流程：

```
prediction_result = connection.execute(prediction).fetchall()
reference_result = connection.execute(reference).fetchall()
execution_correct = prediction_result == reference_result
```

数据库只用于测试时，通常不会增加模型训练时间；只有将数据库执行结果作为训练 reward 或反馈时，才会显著增加训练成本。

6 Label 解码注意事项

DataCollatorForSeq2Seq 会将 label padding 设置为 -100，让 loss 忽略这些位置。这对训练是正确的，但在 evaluation 解码参考 SQL 前，需要先替换回 tokenizer 的 padding token：

```
labels = batch["labels"].clone()
labels[labels == -100] = tokenizer.pad_token_id

references = tokenizer.batch_decode(
    labels,
    skip_special_tokens=True
)
```

模型预测则应使用 `model.generate()`：

```
generated_ids = model.generate(
    input_ids=batch["input_ids"],
    attention_mask=batch["attention_mask"],
    max_length=MAX_TARGET_LENGTH
)

predictions = tokenizer.batch_decode(
    generated_ids,
    skip_special_tokens=True
)
```

如果直接把包含 -100 的 labels 解码，或者没有使用 `generate()`，评估结果可能会被错误地压低。

7 最终建议

在当前数据条件下，建议报告如下结果：

表 2: 推荐的最终评估报告格式

指标	说明
Exact Match	严格字符串完全匹配
Normalized Exact Match	基础标准化后的字符串匹配
SQL Validity Rate	能被 SQLite SQL parser 解析的比例
Execution Accuracy	若没有匹配数据库实例，则不报告

推荐在报告中写明：

由于当前提供的数据文件包含 schema、自然语言问题及参考 SQL，但不包含可用于执行查询的匹配数据库实例，因此本文不计算 Execution Accuracy。我们报告 Exact Match、Normalized Exact Match 和 SQL Validity Rate，以分别衡量严格匹配、格式差异下的匹配以及生成 SQL 的基本语法有效性。

如果作业要求只提供一个主要指标，可以将 **Normalized Exact Match** 作为主要字符串指标，同时保留 Exact Match 作为严格基线。报告中必须清楚写出指标定义，避免将严格的 Exact Match 直接表述为完整的 SQL 语义准确率。